



COMP9517

期末班

Final-2 期末课讲解

TUTOR: Plum

时长: 2 小时

本节内容预览:

1. Color
2. Texture: Haralick, LBP, SIFT
4. Shape
5. HOG
6. PR: Classification, Regression, Evaluation

14 题



Features

图像特征本质上是向量，是图像的压缩（compact representation）表示。

为什么不直接使用 pixel？

- Pixel values change with light intensity, colour, angle
- They also change with camera orientation
- And they are highly redundant

Desirable properties of features

- Reproducibility (robustness)
 - ✓ Should be detectable at the same locations in different images despite changes in illumination and viewpoint
- Saliency (descriptiveness)
 - ✓ Similar salient points in different images should have similar features
- Compactness (efficiency)
 - ✓ Fewer features
 - ✓ Smaller features

a) 习题

Which one of the following statements is incorrect about why pixel values are normally not used directly as features?

- A. Pixel values may change with illumination intensity.
- B. Pixel values can be affected by camera orientation.
- C. Pixel values are typically highly redundant.
- D. Pixel values do not possess translation invariance.



ELLE学姐



ECHO学姐




Colour Features

Invariant to image scaling, translation and rotation

A. Colour Histogram

表示图像中像素颜色的全局分布

- Step 1: 为每个颜色通道 (R, G, B) 构建直方图
- Step 2: 连接所有通道的直方图作为最终的特征向量



颜色直方图的特征向量维度: [1, 768]

B. Colour Moments

基于 RGB 图像每个通道的均值、方差、偏度

- First-order moment $\mu_i = \frac{1}{N} \sum_{j=1}^N f_{ij}$ (mean)
- Second-order moment $\sigma_i = \left(\frac{1}{N} \sum_{j=1}^N (f_{ij} - \mu_i)^2 \right)^{\frac{1}{2}}$ (variance)
- Third-order moment $s_i = \left(\frac{1}{N} \sum_{j=1}^N (f_{ij} - \mu_i)^3 \right)^{\frac{1}{3}}$ (skewness)

特征向量只有 $3 \times 3 = 9$ 个元素，表达能力弱于 Colour Histogram。

Tips: 颜色特征只考虑图像的颜色，但是此特征会受到光照的影响！



ELLE学姐



ECHO学姐



Texture features

- Visual characteristics and appearance of objects
- Properties of structural homogeneity beyond colour or intensity
- Especially used for texture classification

A. Haralick texture features

获得一组统计描述符（Statistical descriptors），用于捕捉图像中相邻像素间的空间关系。

a) 实现步骤

Step1: 构建灰度共生矩阵（gray-level co-occurrence matrix, GLCM）

- 记录具有特定空间关系的两个像素值在图像中一起出现的角度和距离。
- 选择不同的距离和角度，出现频率，可以构造不同的共生矩阵（会算）

Example image:

$L = 4$

0	0	0	0	1	1	1	2
0	0	0	1	1	2	2	3
0	0	1	1	2	2	3	3
0	2	2	3	3	2	2	1
2	2	3	3	3	2	1	1
2	3	3	3	2	2	1	0
3	3	2	2	1	1	0	0
3	2	2	1	1	0	0	0

Corresponding example co-occurrence matrices:

$P_{(1,0^\circ)} =$

18	6	1	0
6	14	8	0
1	8	16	10
0	0	10	14

$P_{(1,90^\circ)} =$

18	5	2	0
5	10	8	2
2	8	14	11
0	2	11	14

计算灰度共生矩阵的方向一般为 0° , 45° , 90° , 135° 四个方向。




Fig. 1 Resolution cells 1 and 5 are 0° (horizontal) nearest neighbors to resolution cell *; resolution cells 2 and 6 are 135° nearest neighbors; resolution cells 3 and 7 are 90° nearest neighbors; and resolution cells 4 and 8 are 45° nearest neighbors to *. (Note this information is purely spatial, and has nothing to do with gray-tone values.)

矩阵是对角线对称的

Step2: 计算 Haralick 特征描述符

- 从 GLCM 中提取多种统计量，如对比度、均匀性、相关性和熵等。



ELLE学姐



ECHO学姐




B. Local Binary Pattern

LBP 具有旋转不变性 (rotation-invariant) 和多分辨率 (multiresolution)。


a) 原理

- 在一个 3×3 的窗口内，以窗口中心像素为阈值，与相邻的 8 个像素的灰度值比较，若周围的像素值大于中心像素值，则该位置被标记为 1，否则标记为 0。
- 如此可以得到一个 8 位二进制数，再转换为 10 进制。将这个十进制的值作为窗口中心像素点的 LBP 值，以此表示这个 3×3 区域的纹理信息。





b) 性质：旋转不变性 Rotation-invariant

- 无论图像如何旋转，LBP 都能产生相同或相似的特征表示。



Note: not all patterns have 8 shifted variants (e.g. 11001100 has only 4)

- 统计每个区域（滑动窗口）内各个 LBP 值 (0 到 255) 的出现次数，生成 256 维的直方图。
- 将所有区域的直方图拼接在一起，形成图像的最终 LBP 特征向量。



ELLE学姐




ECHO学姐



c) 性质：多分辨率 multiresolution

改变中心像素和相邻像素之间的距离，改变相邻像素的数量。



ELLE学姐



ECHO学姐




C. Scale-Invariant Feature Transform

SIFT 在图像中检测出**关键点**（**局部特征描述子**）

- 描述关键点周围区域的纹理特征，
- 具有**尺度**（scale）和**方向/旋转**（orientation、rotation）不变性。

步骤：




a) SIFT Extrema Detection

目的：使用高斯差分（DoG）识别对尺度和方向具有不变性的潜在关键点。

步骤：

1. 对原始图像使用一系列不同尺度（scale, σ ）的高斯滤波，得到一系列平滑图像，组成“尺度空间 scale space”。
2. 相邻的平滑图像相减，得到一系列 DoG 图像。
3. 在 DoG 图像中，每个像素都与它同一尺度中的 8 个相邻像素以及上下两个尺度中相对应位置的 9×2 个像素（总共 26 个邻居）比较。如果该像素是这 26 个像素中的最大值或最小值，它就被认为是一个**极值点**（候选关键点）。



ELLE学姐



ECHO学姐



b) SIFT Keypoint Localization

目的：消除对比度低或沿边缘定位不良的点。

方法：每个候选关键点都通过三维二次拟合（3D quadratic fitting）来精确到亚像素（subpixel）级别，从而细化。再通过 Hessian 矩阵分析来排除低对比度点和边缘点。



Initial keypoints from
scale-space optima


Keypoints after rejecting
low-contrast points

Final keypoints after
rejecting edge points

c) SIFT Orientation Assignment

目的：为每个关键点分配方向，使 SIFT 描述符对图像具有旋转不变性。

方法：通过关键点的局部梯度方向构建方向直方图，直方图的主峰确定了关键点的主方向。



Step 1. 分割邻域区域

- 首先，以关键点为中心，选择 16×16 像素的邻域区域。
- 将这个 16×16 的邻域区域分割成 4×4 的子区域（即每个子区域包含 4×4 个像素），这样总共得到 16 个子区域。

Step 2. 计算梯度方向直方图

- 对每个子区域，计算其中每个像素的梯度幅度和方向。
- 根据像素的梯度方向，填充一个包含 8 个 bin 的梯度方向直方图（每个 bin 代表一个方向范围，例如 0-45 度，45-90 度等）。方向直方图中的每个 bin 值是该方向上的梯度幅度的累积值。



ELLE学姐




ECHO学姐



Step 3. 获得主方向

- 在计算梯度方向直方图时，坐标系会根据关键点的主方向进行旋转，从而实现方向不变性。



如果次高峰的峰值大于主峰的 80%，则为该方向创建一个新关键点。

Step 4. 生成特征向量 SIFT Keypoint Descriptor

- 每个 4×4 子区域的梯度方向直方图包含 8 个 bin。
- 共有 16 个子区域，因此每个关键点会得到一个包含 128 维的特征向量。

d) 例子

旋转之前的直方图

角度	0-44	45-89	90-134	135-179	180-224	225-269	270-314	314-360
频数	80	100	120	300	400	200	100	80

频数最高的为 400，[180-224] 角度，确定为主峰，那我们进行旋转，通常将主峰归为 0 度。

角度	0-44	45-89	90-134	135-179	180-224	225-269	270-314	314-360
频数	400	200	100	80	80	100	120	300

这个子区域由频数的特征向量为 [400,200,100,80,80,100,120,300]



ELLE学姐




ECHO学姐



D. NNDR

最近邻距离比



在 128 维特征空间中寻找最近邻点，用于判断两个特征是否匹配

基于它到 最近邻 和 次近邻 的距离比

$$\text{NNDR} = \frac{d_1}{d_2} = \frac{\|D_A - D_B\|}{\|D_A - D_C\|}$$

其中， d_1 是到第一个最近邻的距离，而 d_2 是到第二个最近邻的距离。

D_A 表示当前特征点， D_B 是第一个最近邻（最接近 D_A 的点）， D_C 是第二个最近邻（第二接近 D_A 的点）。

首先计算 D_A 到 D_B 的欧氏距离 $\|D_A - D_B\|$ ，然后计算 D_A 到 D_C 的欧氏距离 $\|D_A - D_C\|$ ，将这两个距离相除得到 NNDR 值。

拒绝匹配的标准是 NNDR 大于 0.8，意味着如果 D_A 和 D_B 的相似度不显著高于 D_A 和 D_C 的相似度，则认为这不是一个好的匹配。

（如果两个近邻都很近，很像，说明这些特征可能比较常见，不合适做匹配）

a) 习题

Which three of the following statements about feature descriptors is **incorrect**?

- A. Haralick features are derived from gray-level co-occurrence matrices.
- B. SIFT achieves rotation invariance by computing gradient histograms at multiple scales.
- C. SIFT achieves scale invariance by computing gradient histograms at multiple scales.
- D. LBP describes local image texture and can be multiresolution and rotation-invariant.
- E. Colour moments have lower representation capability than the colour histogram.



ELLE学姐



ECHO学姐



E. RANSAC

a) 问题背景

在图像匹配过程中，尽管多数匹配关系是正确的，但仍然可能包含一些错误的匹配（即离群点 outliers）。

这些错误的匹配会对普通的最小二乘法拟合产生负面影响，导致拟合结果不准确。

b) RANDOM Sample Consensus (RANSAC)

通过迭代过程从一组**包含离群点**的数据中估计出数学模型的参数。

并非使用所有数据点来估计模型参数，而是随机选择一小部分数据（样本）来估计模型，并验证这个模型与其他数据的一致性。只有那些**被当前模型很好地预测的数据点（内点）**才会用于最终确定模型参数。

c) 算法步骤

1. 随机选择最小的数据集，足够确定模型参数。
2. 使用选定的样本数据集计算模型参数。
3. 确定有多少数据点适合于估计的模型（计算内点数量）。
4. 重复上述过程多次，每次保留拟合结果最好的模型（内点数最多的模型）。
5. 使用所有内点重新计算/优化模型参数。



ELLE学姐




ECHO学姐



a) Sample

- RANSAC




Algorithm:

1. **Sample** (randomly) the number of points required to fit the model
2. **Solve** for model parameters using samples
3. **Score** by the fraction of inliers within a preset threshold of the model

Repeat 1-3 until the best model is found with high confidence

- RANSAC




Algorithm:

1. **Sample** (randomly) the number of points required to fit the model
2. **Solve** for model parameters using samples
3. **Score** by the fraction of inliers within a preset threshold of the model

Repeat 1-3 until the best model is found with high confidence

- RANSAC




Algorithm:

1. **Sample** (randomly) the number of points required to fit the model
2. **Solve** for model parameters using samples
3. **Score** by the fraction of inliers within a preset threshold of the model

Repeat 1-3 until the best model is found with high confidence

- RANSAC



Algorithm:

1. **Sample** (randomly) the number of points required to fit the model
2. **Solve** for model parameters using samples
3. **Score** by the fraction of inliers within a preset threshold of the model

Repeat 1-3 until the best model is found with high confidence



ELLE学姐



ECHO学姐



Feature Encoding (BoW)

问题背景：就 SIFT 而言，不同的图片会有不同数量的 keypoints，意味着不同数量的特征描述符。

导致特征无法直接送入模型进行训练！


Bag-of-Words (BoW): 将可变的局部图像特征转化成固定维数的直方图，来表示每个图片。

A. Recap of k-means clustering

Initialize: k cluster centres (typically randomly)

Iterate: 1. Assign data (feature vectors) to the closest cluster (Euclidean distance)
2. Update cluster centres as the mean of the data samples in each cluster

Terminate: When converged or the number of iterations reaches the maximum



ELLE学姐




ECHO学姐



B. Bow 步骤

a) Step1. 全局特征提取

对于所有的训练图像，提取局部 SIFT keypoint descriptors (得到很多特征描述子)



b) Step2. 创建视觉词汇表 (Create Visual Vocabulary)

- 通过 K-means 聚类算法，将得到的局部特征描述子分组聚类，以创建固定数量 (K) 的簇。每个簇的中心点代表一个视觉单词 (visual word)。
- 所有簇中心点的集合构成了视觉词汇表 (Visual Vocabulary)。


c) Step3. 生成图像直方图

- 提取每张图片中的局部特征描述子，计算它们分别属于词汇表的哪个视觉单词。每个视觉单词中的描述子个数为直方图的频数。
- 这些频数构成了一个频率直方图，形成 BoW 表示。



将每个特征描述子分配给距离最近的 visual word。

对于每个图像，计算每个视觉单词中特征描述子的频数。



ELLE学姐




ECHO学姐



C. Example application of feature encoding


SIFT-based texture classification



SIFT-based texture classification

- ➔ Build vocabulary
- ➔ Train classifier
- ➔ Classify image

<http://heragi.blogspot.com/2017/03/BoW.html>



a) 习题

Which one of the following statements about BoW feature encoding for SIFT is incorrect?

- A. BoW uses a vocabulary constructed from a training set of SIFT keypoint descriptors.
- B. BoW assigns each SIFT keypoint descriptor to the visual word with the largest distance.
- C. BoW counts the number of SIFT keypoint descriptors assigned to each visual word.
- D. BoW encodes all SIFT keypoint descriptors of an image into a fixed-dimensional histogram.



ELLE学姐



ECHO学姐



Shape

- Shape is an essential characteristic of material objects
- Shape features are typically extracted after image segmentation
- They can be used to identify and classify objects


Challenges in defining shape features

- ◆ Invariant to rigid transformations 刚性变换
- ◆ Tolerant to non-rigid deformations 非刚性变形

关注物体的几何特征、轮廓、边界；而不是 viewpoint、illumination

凸对象：任意两点之间的直线段都在对象内部。

凹对象：存在两点之间的直线段不在对象内部。




D. 简单几何形状描述符

紧致度 (Compactness)：适用于分析细长或扁平的形状。

- 面积 和 周长相同的圆面积 的比率
- 紧凑度值越大，形状越不规则。

圆形度 (Circularity)：衡量一个对象与完美圆形相似程度的指标

- 值越接近 1，形状越接近圆。
- $4 \pi * \text{面积} / (\text{周长的平方})$



延展度 (Elongation)：适用于分析细长或扁平的形状。

- ◆ 对象边界框的长度与宽度之比

离心率 (Eccentricity)：适用于椭圆形状的分析。

- ◆ 次轴长度与主轴长度之比
- ◆ 主轴指向物体质量分布最广的方向，次轴指向物体密度最大的方向。



ELLE学姐



ECHO学姐




a) 习题

Question: Given the image below showing the result of a segmentation of various objects and the desired classification of these objects. The two different colours (red and green) indicate the two different classes which the objects are to be assigned to.

A straightforward way to perform classification is by computing the value of a quantitative shape measure for each object and then thresholding those values. Suppose we compute the circularity and the eccentricity. Which of these two measures can be used to produce the shown classification?

- A. Only circularity
- B. Only eccentricity
- C. Both circularity and eccentricity
- D. Neither circularity nor eccentricity



b) 习题

一个对象的面积 (area) 和周长 (perimeter) 都是 25, 它的圆度 (circularity) 是多少?



ELLE学姐



ECHO学姐




E. 边界描述符

a) 链码描述符 (Chain Code Descriptor)局部特征

- ◆ 通过连续边界点的相对位置来表示对象的形状。
Represents object shape by the relative positions of consecutive boundary points
- ◆ 包含从起始点开始的一系列方向列表。
Consists of a list of directions from a starting point
- ◆ Provides a compact boundary representation


5	6	7
4	↖ ↗ ↘ ↙	0
3	2	1



Example:
6,7,0,1,1,0,7,7

b) 局部曲率描述符 (Local Curvature Descriptor)

- ◆ 曲率是对象的局部形状属性。
The curvature of an object is a local shape attribute
- ◆ 凸（或凹）部分具有正（或负）曲率。
Convex (versus concave) parts have positive (versus negative) curvature



c) 习题

In local curvature descriptors, what do the positive and negative values of curvature indicate?

- Positive indicates concave, negative indicates convex
- Positive indicates convex, negative indicates concave.
- Positive indicates flat, negative indicates undulating
- Positive indicates convex, negative indicates flat



ELLE学姐



ECHO学姐




d) 全局曲率描述符 (Global Curvature Descriptors)

- ◆ 总弯曲能量 (Total Bending Energy) $B = \int_C \kappa^2(s) ds$
 - ◆ 总弯曲能量表示物体轮廓的弯曲所存储的物理能量。
Amount of physical energy stored in a rod bent to the contour
 - ◆ 圆形物体的轮廓弯曲能量最小，公式为 $B = \frac{2\pi}{r}$ 。
Circular objects have the smallest contour bending energy
- ◆ 总绝对曲率 (Total Absolute Curvature) $K = \int_C |\kappa(s)| ds$
 - ◆ 总绝对曲率是沿物体轮廓积分的曲率的绝对值。
Absolute value of the curvature integrated along the object contour
 - ◆ 凸物体的总绝对曲率最小，公式为 $K = 2\pi$ 。
Convex objects have the smallest total absolute curvature

e) 径向距离描述符 (Radial Distance Descriptor)

- 使用形状的质心 C 作为参考点，计算其边界上所有 N 像素点 i 的径向距离 d 。Use the centroid C of the shape as the reference point and compute the radial distance d for all N pixels i along its boundary
- 通过将 $d(i)$ 归一化为最大距离来实现尺度不变性，得到径向距离 $r(i)$ 。
Scale invariance is achieved by normalizing $d(i)$ by the maximum distance to obtain the radial distance $r(i)$
- $r(i)$ 信号穿越其平均值的次数可以用作边界粗糙度的度量。
The number of times the signal $r(i)$ crosses its mean can be used as a measure of boundary roughness



ELLE学姐



ECHO学姐




Histogram of Oriented Gradients

方向梯度直方图（HOG）特征是一种目标检测的特征描述子。


不需要初始分割（initial segmentation）

启发：在图像中，目标的形状能够被梯度或边缘特点描述。所以我们可以通
过计算和统计图像局部区域的梯度方向直方图来构成特征。




A. 第一步：检测窗口的构建

1. 使用梯度算子计算每个像素的梯度大小和方向
2. 将图像分为多个单元格（cell）
3. 将一个 cell 中，根据梯度方向将每个像素分配到相应的方向 bin 中
(均匀划分 180 度，每个 bin 20 度)
4. 在 cell 内，对所有像素的梯度方向和幅值进行统计，形成梯度方向直方图。



5. 将每个单元格的梯度方向直方图的特征描述子连接起来，并进行块归一化（Block-normalise, 降低光照条件的影响），以生成检测窗口级别的 HOG 描述子。



Detection window 有 7*15 个 blocks；每个 block 有 2*2 个 cells；每个 cells 内有 8*8 个像素，组成了一个 9 个方向的梯度直方图。将检测窗口内的所有特征描述子串联起来就可以得到 HOG 特征向量。



ELLE学姐




ECHO学姐



B. 第二步：响应图

a) 训练

1. 有训练集 training dataset 和测试集 test dataset
2. 训练集和测试集一样，都有图片 img 和标签 label。（一张图可能有多个标签），此标签包含信息有边界框 bounding box 的位置坐标，还有内部物体所属类别。




3. 模型会针对边界框内部的特征和标签进行学习。这是一个分类任务，基于特征进行分类。
4. 模型训练完毕后，可以用测试数据集进行测试嘛。模型会预测出测试图片 bbox 的标签类别，并且和真实的标签进行比较，得到评价指标。


b) 测试

在测试过程中，模型会对整张图进行遍历，并且记录每个部分的可能性，输出成图片，即响应图。

HOG feature map



Detector response map



响应图显示了分类器对图像中每个检测窗口的响应。

- 颜色表示响应强度，黄色和绿色区域表示高响应，可能包含目标对象。
- 蓝色和紫色区域表示低响应，可能是背景不包含目标对象的区域。



ELLE学姐



ECHO学姐



知识蒸馏

为什么不直接用 pixel? 三个原因

Image feature 的三个特点: Reproducibility、Saliency、Compactness

Color: 表达能力 Colour Moments < Colour Histogram

Haralick 通过图片会计算共生矩阵。

LBP: 旋转不变性 (rotation-invariant) 和多分辨率 (multiresolution) 以及为什么。

SIFT 的流程、两个性质

- ◆ 尺度不变性: 不同尺度的高斯滤波, 得到尺度空间。
- ◆ 方向不变性: 关键点会根据主峰旋转。

RANSAC 可以缓解包含离群点的数据。

BoW 将可变的局部图像特征转化成固定维数的直方图, 以此来表达每张图片。

Shape 特征的特点

简单几何描述符的计算公式和应用场景。

HOG 用来做目标检测的流程。



ELLE学姐



ECHO学姐



Pattern Recognition

A. 种类

Supervised learning

- ◆ Learning patterns in a set of data with available labels (ground truth)

Unsupervised learning

- ◆ Finding patterns in a set of data without any labels available

Semi-supervised learning


- ◆ Using a combination of labelled and unlabelled data to learn patterns

Weakly supervised learning

- ◆ Using noisy / limited / imprecise supervision signals in learning of patterns



Generative models

- Model the “mechanism” by which the data was generated
- Represent each class by a probabilistic “model” $p(x|y)$ and $p(y)$
- Applicable to unsupervised learning tasks (unlabelled data)



Discriminative models

- Focus on explicit modelling of the decision boundary
- Applicable to supervised learning tasks (labelled data)



分类任务

- 模型接收一个输入（通常是特征向量）并输出一个类别标签。
- 根据类别的数量，可以进一步分为二分类任务和多分类任务。

回归任务

- 模型接收一个输入（通常是特征向量）并输出一个数值。



ELLE学姐



ECHO学姐



B. Terminology

Objects are (identifiable) physical entities of which images are taken

Regions (ideally) correspond to objects after image segmentation

Classes are disjoint subsets of objects sharing common features

Labels are associated with objects and indicate to which class they belong

Classification is the process of assigning labels to objects based on features

Classifiers are algorithms/methods performing the classification task

Patterns are regularities in object features and are used by classifiers

Pre-processing aims to enhance images for further processing

Feature extraction reduces the data by measuring certain properties

Feature descriptors represent scalar properties of objects

Feature vectors capture all the properties measured from the data

Feature selection aims to keep only the most descriptive features

Models are (mathematical or statistical) descriptions of classes

Training samples are objects with known labels used to build models

Cost is the consequence of making an incorrect decision/assignment

Decision boundary is the demarcation between regions in feature space



ELLE学姐



ECHO学姐




Nearest Class Mean Classifier

最近类均值分类器

A. 基于最小距离原理

- 在训练数据集中，为每个类别计算一个质心 centroid（可能不止一个）。
- 现在有一个未知类别的点 X ，计算这个未知点 X 距离所有质心的距离，将最近的质心所属类别分配给这个未知点。



- 给定训练样本对 $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，每个类别 k 的质心计算：

$$\mu_k = \frac{1}{|c_k|} \sum_{x_i \in c_k} x_i$$

其中， μ_k 是类别 k 的质心， $|c_k|$ 是类别 k 中样本的数量， $\sum$ 表示对属于类别 k 的所有样本求和。

B. Pros&Cons

Pros

- Simple, Fast
- Works well when classes are compact and far from each other

Cons

- Poor results for complex classes (multimodal, non-spherical)
- Cannot handle outliers and noisy data well



ELLE学姐





ECHO学姐



K-Nearest Neighbours Classifier

猜猜看最后的 G 点属于哪一类？

点	x_1	x_2	电影类型
A点	1	101	爱情片
B点	5	89	爱情片
C点	12	97	爱情片
D点	108	5	动作片
E点	112	9	动作片
F点	115	8	动作片
G点	24	67	?



A. 计算步骤

1. 算距离：给定测试对象，计算它与训练集中的每个样本对象的距离；
2. 找邻居：圈定距离最近的K个训练对象，作为测试对象的近邻；
3. 做分类：根据这K个近邻归属的主要类别，来对测试对象分类。

B. Pros&Cons

Pros

- ◆ Very simple and intuitive
- ◆ Easy to implement
- ◆ No a priori assumptions
- ◆ No training step
- ◆ Decision surfaces are non-linear

Cons

- ◆ Slow algorithm for big data sets
- ◆ Needs homogeneous (similar nature) feature types and scales
- ◆ Does not perform well when the number of variables grows (curse of dimensionality)
- ◆ Finding the optimal K (number of neighbours) to use can be challenging



ELLE学姐



ECHO学姐



Bayes Decision Theory

A. 基本假设&后验概率计算

基于观测到的特征(先验信息), 贝叶斯分类将对象分配到最可能的类别中。

假设已知以下信息:

- 先验概率 $p(c_i)$: 每个类别 c_i 的先验概率。
- 条件分布 $p(x|c_i)$: 在类别 c_i 下, 特征 x 的条件分布。

需要计算后验概率 $p(c_i|x)$: 在给定特征 x 的情况下, 样本属于类别 c_i 的概率。

根据贝叶斯定理, 计算公式为:

$$p(c_i|x) = \frac{p(x|c_i)p(c_i)}{\sum_j p(x|c_j)p(c_j)} = \frac{p(x|c_i)p(c_i)}{p(x)} \propto p(x|c_i)p(c_i)$$

由于 $p(x)$ 是一个常数, 可以简化为只需比较 $p(x|c_i)p(c_i)$ 的值, 而不需要计算标准化常数 $p(x)$ 。

B. 决策规则

为了做出分类决策, 使用最大后验概率 (MAP) 准则:

$$c = \arg \max_i (p(c_i|x)) \Rightarrow \arg \max_i (p(x|c_i)p(c_i))$$

找到基于特征 x , 类别 c 属于的最大类别。



ELLE学姐



ECHO学姐



C. Example: 计算

假设我们想要将鱼的种类进行分类: salmon, sea bass, other
有过去的经验(先验信息), 每类的概率:

$p(c_i)$	Salmon	Sea bass	Other
Prior	0.3	0.6	0.1

只从经验判断每类鱼钓上来的概率, 不看鱼的特征, 直接判断鱼的种类。

这样的准确率可能会偏低, 所以我们可以再多考虑一个特征: length

从过去的经验, 我们知道如下条件概率:

$p(x c_i)$	Salmon	Sea bass	Other
length > 100 cm	0.5	0.3	0.2
50 cm < length < 100 cm	0.4	0.5	0.2
length < 50 cm	0.1	0.2	0.6

那么, 我们可以使用后验概率进行推测:

$$p(c_i|x) \propto p(x|c_i)p(c_j)$$

- If we have a fish with **length 70 cm**, what would be our prediction?

$$p(c_i = \text{salmon} | x = 70 \text{ cm}) \propto p(70 \text{ cm} | \text{salmon}) * p(\text{salmon}) = 0.4 * 0.3 = 0.12$$

$$p(c_i = \text{sea bass} | x = 70 \text{ cm}) \propto p(70 \text{ cm} | \text{sea bass}) * p(\text{sea bass}) = 0.5 * 0.6 = 0.30$$

$$p(c_i = \text{other} | x = 70 \text{ cm}) \propto p(70 \text{ cm} | \text{other}) * p(\text{other}) = 0.2 * 0.1 = 0.02$$

- Based on these probabilities, we predict the type as **sea bass**

D. Pros&Cons

Pros

- Simple and efficient
- Considers uncertainties
- Permits combining new information with current knowledge

Cons

- Struggles with complex data relationships
- Choice of priors can be subjective



ELLE学姐



ECHO学姐



Decision Trees

决策树由结点（node）和有向边（directed edge）组成。



- ◆ 两种结点：内部结点（internal node）和叶结点（leaf node）。
- ◆ 内部结点表示一个特征或属性，叶结点表示一个类。

E. 算法

假设有两个特征：Length (x_1), Width (x_2)

步骤：

1. 选择要放置在 node 上的特性(第一个 node 是 root)
2. 为每个可能的值，或范围创建一个分支
3. 对于每个分支 node，对到达该分支的样本，重复步骤 1 和 2
4. 当一个节点上的所有样本都具有相同的分类时，停止生长这部分树



F. 特征选择标准——Entropy&Information Gain

- 熵（entropy）是表示随机变量不确定性的度量。
- 设 X 是一个取有限个值的离散随机变量，其概率分布为 $P(X = x) = p_i, i = 1, 2, \dots, n$ ，则随机变量 X 的熵定义为

$$H(p) = - \sum_{i=1}^n p_i \log p_i$$

熵越大，随机变量的不确定性就越大。

当 $p = 0$ 或 $p = 1$ 时 $H(p) = 0$ ，随机变量完全没有不确定性。当 $p = 0.5$ 时， $H(p) = 1$ ，熵取值最大，随机变量不确定性最大。（以 2 为底）



ELLE学姐



ECHO学姐



G. Entropy 计算例子

Let us look at the fish example

$p(c_i)$	Salmon	Sea bass	Other
Prior	0.3	0.6	0.1

The entropy (uncertainty) of information (type of fish) is:

$$H = -[0.3 * \log(0.3) + 0.6 * \log(0.6) + 0.1 * \log(0.1)] = 1.29$$

H. Pros&Cons

Pros

- Easy to interpret
- Can handle both numerical and categorical data
- Robust to outliers and missing values
- Gives information on importance of features (feature selection)

Cons

- Tends to overfit
- Only axis-aligned splits
- Greedy algorithm (may not find the best tree)



ELLE学姐



ECHO学姐




Random Forests

I. Ensemble Learning

集成学习的思想：将多个模型组合之后产生一个新模型。这些模型可以使用不同的训练算法、参数、训练集、特征集。

J. RF 步骤

1. 从原始样本集（ n 个样本）中用 Bootstrap 采样（有放回重采样）选出 n 个样本；
2. 使用抽取出来的子数据集（存在重复数据）来训练决策树；从所有属性中随机选择 m 个属性，从 m 个属性中选择出最佳分割属性作为当前节点的划分属性，按照这种方式来迭代的创建决策树。
3. 重复以上两步 B 次，即建立 B 棵决策树；
4. 这 B 个决策树形成随机森林，通过投票表决结果决定数据属于那一类。



ELLE学姐



ECHO学姐



K. Tips

The random forest error rate depends on two factors:

1. Correlation between any two trees in the forest Increased correlation increases the forest error rate; uncorrelated trees lead to better generalization.
2. Strength of each individual tree in the forest
 - Strong tree has low error rate
 - Increasing the strength of individual trees decreases the forest error rate

Selecting parameter m

- Reducing m reduces both the correlation and the strength
- Increasing m increases both the correlation and the strength
- Somewhere in between is an “optimal” range of values for m

a) 梳理

- 增加 correlation => 增加 error rate
- 减少 correlation => 减少 error rate => 增加泛化能力
- 增加 m 选择的特征数量 => 增加 correlation & strength
- 减少 m 选择的特征数量 => 减少 correlation & strength

L. Pros&Cons

Pros

- High accuracy among traditional classification algorithms for many problems
- Works efficiently and effectively on large datasets
- Handles thousands of input features without feature selection
- Handles missing values effectively

Cons

- Less interpretable than an individual decision tree
- More complex and more time-consuming to construct than decision trees

a) 习题

Which one of the following statements is correct for random forest classifiers?

- A. Increasing the correlation between the individual trees decreases the random forest classification error rate.
- B. Reducing the number of selected features at each node increases the correlation between the individual trees.
- C. Reducing the number of selected features at each node increases the strength of the individual trees.
- D. Increasing the strength of the individual trees decreases the random forest classification error rate.



ELLE学姐



ECHO学姐




Separability


如果存在一个判别子空间将特征空间分隔开来,使得每个区域内只有一个类别的对象。

(判别子空间在二维中对应一条直线,在三维中对应一个平面,在高维空间中对应一个超平面)


A hyperplane in $\mathbb{R}^2$ is a line




A hyperplane in $\mathbb{R}^3$ is a plane



例如:左图表示线性可分 (linearly separable) 的情况,一个直线将两个类别分开。右图表示非线性 (non-linearly separable) 可分的情况,无法用直线分开。



Linearly separable



non-linearly separable

[Source](#)



ELLE学姐




ECHO学姐



Support Vector Machines (SVMs)

可以使用的超平面可能有多，所以我们需要在其中选择最优的一个。



- SVM 的目标：**最大化超平面到最近样本点的距离**，并确保正类和负类样本在超平面的两侧。
- 最接近超平面的样本点称为**支持向量**。间隔越大，分类器的泛化能力越好。

M. Hard-margin

对于硬间隔线性 SVM，我们假设数据是线性可分的，并且不允许任何样本被错误分类。

$$y_i(w^T x_i + b) \geq 1$$

在硬间隔 SVM 中，假设类别是线性可分的，但如果这种可分性假设不成立呢？（可能会有部分点一直分得不好）

N. Soft-Margin

引入松弛（slack）变量 ξ_i 允许某些样本被错误分类，从而形成软间隔 SVM。

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

优化目标是最小化间隔的违反度 ξ_i 和权重的平方和：

$$\min_{w, b, \{\xi_i\}} \frac{1}{2} \|w\|_2^2 + C \sum_i \xi_i$$

$$\text{s.t. } y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \forall i, \xi_i \geq 0$$

- 小的 C ：允许更多的误分类样本以获得更大的间隔。
- 大的 C ：更关注避免错误分类，但间隔可能较小。
- (C 趋于无穷大时回到硬间隔 SVM)



ELLE学姐




ECHO学姐



O. Nonlinear Support Vector Machines

为了生成非线性决策边界，可以将特征映射到一个新的特征空间。在这个新空间中类别是线性可分的，然后在新空间中应用 SVM。



核函数 (Kernel Function)：通过核函数将特征映射到高维空间，从而简化优化问题的复杂性。

P. Pros&Cons

Pros

- Very effective in high dimensional feature spaces
- Effective when the number of features is larger than the training data size
- Among the best algorithms when the classes are (well) separable
- Work very well when the data is sparse
- Can be extended to nonlinear classification via kernel trick

Cons

- For larger datasets it takes more time to process
- Does not perform well for overlapping classes
- Hyperparameter tuning needed for sufficient generalization



ELLE学姐



ECHO学姐



Multiclass

当分类问题中存在两个以上的类别时，需要一个多分类器。有些方法可以直接用于多分类：K 近邻（K-nearest neighbours）、决策树（Decision trees）、贝叶斯技术（Bayesian techniques）

对于不能直接用于多分类问题的方法，可以通过**构建多个二分类器**来转换。

- 一对多（One versus rest）：为每个类别构建一个分类器，将该类别与其他所有类别区分开。将测试样本分配给具有最高置信度分数的类别。
- 一对一（One versus one）：为每对类别构建一个分类器。将测试样本分配给具有最多预测结果的类别。

Q. 一对多

假设我们有三个类别：苹果（Apple）、香蕉（Banana）、樱桃（Cherry）。

- 分类器 1：苹果 vs 非苹果（即香蕉和樱桃）
- 分类器 2：香蕉 vs 非香蕉（即苹果和樱桃）
- 分类器 3：樱桃 vs 非樱桃（即苹果和香蕉）

对于一个新样本，我们通过这三个分类器进行预测，假设结果是：

- 分类器 1：苹果（置信度 0.7）
- 分类器 2：香蕉（置信度 0.4）
- 分类器 3：樱桃（置信度 0.6）

最终预测结果为苹果，因为分类器 1 的置信度最高。

R. 一对一

假设我们有三个类别：苹果（Apple）、香蕉（Banana）、樱桃（Cherry）。

- 分类器 1：苹果 vs 香蕉
- 分类器 2：苹果 vs 樱桃
- 分类器 3：香蕉 vs 樱桃

对于一个新样本，我们通过这三个分类器进行预测，假设结果是：

- 分类器 1：苹果
- 分类器 2：苹果
- 分类器 3：香蕉

根据结果我们判断新样本是苹果。

（如果出现平票情况，可以根据分类器的置信度进行决策或者使用其他决策规则）



ELLE学姐



ECHO学姐



a) 习题

In multiclass problems, what does the "one-vs-all" method mean?

- A. Building a classifier for each class to separate it from all other classes.
- B. Building a classifier for each pair of classes
- C. Building a classifier for each sample
- D. Building a classifier for each feature

In multiclass problems, what does the "one-vs-one" method mean?

- A. Building a classifier for each pair of classes.
- B. Building a classifier for each class
- C. Building a classifier for each sample
- D. Building a classifier for each feature

Which of the following methods can be directly used for multiclass classification?

- A. K-nearest neighbors (KNN)
- B. Decision trees
- C. Bayesian techniques
- D. All of the above.

S. 二分类的两类错误

误报 (False alarm or false positive, 称为 I 型错误) :

- 如果某人没有疾病, 但系统错误地认为他们有疾病。

漏报 (False dismissal or false negative, 称为 II 型错误) :

- 如果某人有疾病, 但系统错误地认为他们没有疾病。

错误的后果和成本

- ◆ 一般来说, 漏报 (II 型错误) 更加灾难性。
- ◆ 目标是尽量减少漏报, 即使以增加误报为代价。(宁可错杀, 不可放过一个)
- ◆ 最优/可接受的两种错误的平衡取决于具体应用。



ELLE学姐



ECHO学姐



Evaluation

T. Confusion matrix

For binary classification

		Prediction	
		P	N
Actual	P	# True Positives (TP)	# False Negatives (FN)
	N	# False Positives (FP)	# True Negatives (TN)

A. 评价指标

(sensitivity、specification、recall、precision、TP、FP、TPR、FPR)

Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad \left(\frac{\text{Correct}}{\text{Total}} \right)$$

Precision / correctness

Fraction of relevant elements among the selected elements

$$\text{Precision} = \frac{TP}{TP + FP} \quad (P)$$

Recall / sensitivity / completeness

Fraction of selected elements among the relevant elements

$$\text{Recall} = \frac{TP}{TP + FN} \quad (R)$$

F1 score

Harmonic mean of precision and recall: $F1 = \frac{2PR}{P + R}$

condition positive (P)

the number of real positive cases in the data

condition negative (N)

the number of real negative cases in the data

true positive (TP)

eqv. with hit

true negative (TN)

eqv. with correct rejection

false positive (FP)

eqv. with false alarm, type I error or underestimation

false negative (FN)

eqv. with miss, type II error or overestimation

sensitivity, recall, hit rate, or true positive rate (TPR)

$$\text{TPR} = \frac{TP}{P} = \frac{TP}{TP + FN} = 1 - \text{FNR}$$

specificity, selectivity or true negative rate (TNR)

$$\text{TNR} = \frac{TN}{N} = \frac{TN}{TN + FP} = 1 - \text{FPR}$$

precision or positive predictive value (PPV)

$$\text{PPV} = \frac{TP}{TP + FP} = 1 - \text{FDR}$$

negative predictive value (NPV)

$$\text{NPV} = \frac{TN}{TN + FN} = 1 - \text{FOR}$$

miss rate or false negative rate (FNR)

$$\text{FNR} = \frac{FN}{P} = \frac{FN}{FN + TP} = 1 - \text{TPR}$$

fall-out or false positive rate (FPR)

$$\text{FPR} = \frac{FP}{N} = \frac{FP}{FP + TN} = 1 - \text{TNR}$$



ELLE学姐



ECHO学姐



a) 召回率 (Recall)

- 定义：所有真实的正样本中，被模型正确预测为正的比例。
- 公式： $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
- 核心关注点：避免漏检 (False Negative)。
- 适用场景：当漏检的代价很高时，例如：
 - 医疗诊断（如癌症筛查，需尽可能找到所有患者）。
 - 罕见主题检索（如记者需要覆盖所有相关文章）。
- 缺点：可能引入较多误报 (False Positive)。

b) 精确率 (Precision)

- 定义：模型预测为正的样本中，真实为正的样本比例。
- 公式： $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$
- 核心关注点：减少误报 (False Positive)。
- 适用场景：当误报的代价很高时，例如：
 - 垃圾邮件分类（误将正常邮件标记为垃圾邮件会影响用户体验）。
 - 推荐系统（推荐不相关内容会降低用户信任）。
- 缺点：可能漏检部分正样本。

c) F1 分数 (F1-Score)

- 定义：精确率和召回率的调和平均数，平衡两者关系。
- 公式： $\text{F1} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$
- 核心关注点：综合评估模型性能，尤其适用于数据不平衡的场景。
- 适用场景：需要同时兼顾精确率和召回率时，例如：
 - ✓ 欺诈检测（既要减少漏检欺诈交易，又要避免误判正常交易）。
 - ✓ 搜索引擎排序（既需覆盖相关结果，又需保证结果质量）。

d) 准确率 (Accuracy)

- 定义：所有样本中被正确分类的比例。
- 公式： $\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$
- 核心关注点：整体分类正确性。
- 适用场景：数据分布均衡时，例如：写数字识别（10 个类别分布均匀）。
- 缺点：在数据极度不平衡时可能误导（如 99% 负样本，模型全预测负时准确率仍高达 99%）。

e) 习题 Consider two scenarios

- A journalist J is looking for articles on a rare topic among thousands. J can view many articles but does not want to miss any important. ML model presents a number of articles. Which metric we should apply?
- Recall is relevant here, since it measures proportion of good instances currently classified.



ELLE学姐



ECHO学姐



B. 多分类混淆矩阵

Handwritten digits recognition

class j output by the pattern recognition system


		'0'	'1'	'2'	'3'	'4'	'5'	'6'	'7'	'8'	'9'	'R'
true object class i	'0'	97	0	0	0	0	0	1	0	0	1	1
	'1'	0	98	0	0	1	0	0	1	0	0	0
	'2'	0	0	96	1	0	1	0	1	0	0	1
	'3'	0	0	2	95	0	1	0	0	1	0	1
	'4'	0	0	0	0	98	0	0	0	0	2	0
	'5'	0	0	0	1	0	97	0	0	0	0	2
	'6'	1	0	0	0	0	1	98	0	0	0	0
	'7'	0	0	1	0	0	0	0	98	0	0	1
	'8'	0	0	0	1	0	0	1	0	96	1	1
	'9'	1	0	0	0	3	0	0	1	95	0	0

对角线条目：对角线条目表示分类成功的次数。

非对角线条目：非对角线条目表示分类错误的次数。

C. ROC

- ROC 曲线将假阳性率 (False Positive Rate) 与真阳性率 (True Positive Rate) 联系起来。
- x 轴为 FPR, y 轴为 TPR。
- 右下面积 (AUC 或 AUROC) 总结了整体性能, 曲线右下角面积越大越好



a) 习题

使用 ROC 进行模型效果评估, 下面哪个关于 ROC 的说法是正确的?

- The ROC plot shows the relation between sensitivity and specificity.
- The ROC plot is a method performing random pixel labelling is a straight line.
- The ROC plot of a better method lies above the ROC plot of a worse method.
- The ROC plot is often quantitatively summarized by the area under the curve.



ELLE学姐



ECHO学姐



Linear Regression

- 线性回归假设：输出与特征之间存在线性关系：
- 如何找到最佳拟合线？最小二乘拟合
- 目标是最小化残差平方和（RSS）

D. Evaluation Metrics

a) Root Mean Square Error (RMSE)

Represents the standard deviation of the predicted values from the observed values

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

b) Mean Absolute Error (MAE)

Represents the average of the absolute differences between the predicted and observed values

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

RMSE penalizes big differences between predicted values and observed values more heavily.

Smaller values of RMSE and MAE are more desirable.



ELLE学姐



ECHO学姐



c) R-Squared (R^2)

Indicates how well the selected feature(s) explain the output variable

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

R-squared tends to always increase by adding extra features

R^2 的值范围在 0 到 1 之间，值越接近 1 表示模型越能解释数据的变化。然而， R^2 随着特征的增加往往会增加，即使这些特征没有实际的预测能力。

d) Adjusted R-Squared (Adjusted R^2)

Indicates how well the selected feature(s) explain the output, adjusted for the number of features:

$$R_{\text{adj}}^2 = 1 - \left[\frac{(1 - R^2)(N - 1)}{N - d - 1} \right]$$

where N is the number of samples and d is the number of features

调整后的 R^2 考虑了模型中特征的数量，可以防止添加无关特征使 R^2 偏高。

Larger values of R-Squared and Adjusted R-Squared are more desirable

E. Normalization – preprocess

Goal: to change the scale of numeric values to a common scale

Commonly applied techniques:

- Z-score: re-scales the data (features) such that it will have a standard normal distribution ($\mu = 0, \sigma = 1$), which works well for normally distributed data:

$$\frac{x - \mu}{\sigma}$$

- Min-max normalization: re-scales the range of the data to $[0,1]$ such that the minimum value is mapped to 0 and the maximum value to 1:

$$\frac{x - x_{\min}}{x_{\max} - x_{\min}}$$



ELLE学姐



ECHO学姐



Cross Validation


K 折交叉验证 (K-fold cross validation), 用途:

- ◆ 模型性能评估。例如模型是否可以稳定预测, 而不是因为本次数据的特殊。
- ◆ 超参数调优。每次交叉验证选用不同的参数, 做测试。

F. 性能评估

通常将可用数据随机分为训练集和测试集 (通常为 80:20 的比例), 分别用于训练和测试模型。


将数据分为 K 个子集 (折), 每次迭代时保留一个折进行测试, 其余用于训练。



重复 K 次, 直到每个折都被用作测试集。模型的性能是 K 次测试集性能的平均值。

Cross validation can be used for hyperparameter tuning (or model selection)

- Leave a test set
- Do cross validation on the rest of data with training set and validation set
- Test set cannot be used for selecting the hyperparameter



ELLE 学姐



ECHO 学姐



知识蒸馏

Nearest class mean classifier

- ◆ 基于最小距离原理，计算未知点与所有质心的距离。质心通常为类别内的样本均值。
- ◆ Pros&Cons

KNN: Pros&Cons

Bayes Decision

- ◆ Pros&Cons
- ◆ 计算（没考过）

Random Forest

- ◆ 流程步骤
- ◆ 关系：Correlation、Error rate、特征数量 m 、strength
- ◆ Pros&Cons

SVM

- ◆ 最大化超平面到最近样本点到距离。
- ◆ 最近样本点被称为支持向量。
- ◆ Hard-margin 不允许样本被误分类。
- ◆ Soft-margin 设置松弛 slack 变量违反度，允许少量样本被误分类。
- ◆ 核函数将特征映射到高维空间，从而简化优化问题的复杂性。
- ◆ Pros&Cons

Multi-class (n 类)

KNN、决策树、贝叶斯可以直接用于多分类。

- ◆ 一对多（One versus rest）：为每个类别构建一个分类器。一共构造 n 个分类器。
- ◆ 一对一（One versus one）：为每对类别构建一个分类器。一共构造 $\binom{n}{2}$ 个分类器。

评价指标：Accuracy、Precision、Recall、F1、Sensitivity、specificity

ROC 曲线右下角区域面积越大越好。

线性回归的目的是最小化残差平方和，有两个特有的指标 R^2 和 Adjusted R^2

交叉验证的作用：模型性能评估、超参数调优。



ELLE学姐



ECHO学姐



新南echo学姐：
echo68cpu



新南ella学姐：
lilith0619

CPU·EDU成长有你陪伴
· 让海外学习更轻松 ·