



# COMP9517

## 期末班

**Final-4 期末课讲解**

---

TUTOR: Plum

时长: 2 小时

### 本节内容预览:


1. Linear classifiers
2. Non-linear classifiers – Neural networks
3. Deep Learning – CNNs
4. Classical CNN models

14 题




# CNN

## A. Traditional Approach vs DL Approach



CNN 可以逐步将图像转换为一种特征表示，最终使得这些特征可以通过线性分类器分离。

## B. CNNs- 从低层特征学习到高层



- ◆ 低层特征：CNN 早期层会学习到图像的边缘、线条等低层次特征。
- ◆ 中层特征：中间层则可以识别出更复杂的局部特征，比如物体的某些部分。
- ◆ 高层特征：后期层能够捕捉到物体的全局信息，学习到高级特征，例如面部的整体形状。



ELLE学姐



ECHO学姐



### C. CNN 的特点

- CNNs are used for image recognition, object detection, and classification tasks.
- CNNs excel at analysing complex visual data, such as images and videos. CNNs can automatically detect and recognize patterns, shapes, and objects within images.
- They have spatial invariance, allowing them to recognize objects regardless of location or orientation in an image.
- CNNs excel at feature extraction, learning complex and abstract features from input data.
- Parameter sharing in CNNs reduces computational and memory requirements, which makes them efficient.
- They can be pre-trained on large datasets and fine-tuned for specific tasks, enabling transfer learning.
- CNNs are scalable and can handle inputs of different sizes.

- ✓ 空间不变性：CNN 可以识别对象的位置或方向变化，不受位置影响。
- ✓ 特征提取能力：CNN 能够自动从输入数据中学习复杂的特征。
- ✓ 参数共享：通过共享参数，CNN 减少了计算和内存需求，使其更加高效。
- ✓ 可扩展性：CNN 可以处理不同尺寸的输入数据，且容易通过预训练模型进行微调，支持迁移学习。
- ✓ 自适应学习：CNN 能够自动适应不同的视觉任务，如识别、检测、分割等。
- ✓ 有效性：通过参数共享和局部连接，CNN 对图像的处理非常高效。
- ✓ 良好的泛化能力：CNN 可以在大规模数据集上预训练，并针对具体任务进行微调，具备较强的迁移学习能力。




ELLE学姐



ECHO学姐



# CNN 组成部分



## A. 卷积层 Convolution Layer


卷积层从输入的图像中**提取特征**。

通过应用多个卷积核对输入图像上滑动并与局部像素进行乘积和累加操作，提取边缘、角点等低层次特征，输出特征图（Feature Map）。

## B. 激活函数 ReLU Activation

**ReLU** 是 CNN 中常用的激活函数，它的主要作用是引入**非线性**，使得卷积网络可以处理更复杂的非线性问题，**增强模型的表达能力**。


**ReLU** 将所有小于零的值设为 0，保留大于零的值。



常用非线性激活函数


Sigmoid  

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




Leaky ReLU  

$$\max(0.1x, x)$$




tanh  

$$\tanh(x)$$



Maxout  

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$




**ReLU**  

$$\max(0, x)$$



ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



如果没有激活函数，网络将变得线性，难以解决数据非线性的问题。



ELLE学姐




ECHO学姐



## C. 池化层 Pooling Layer

池化是一个下采样操作，主要目的是通过减少特征图的尺寸，降低计算复杂度，同时保留关键信息。

常见的池化操作包括最大池化(Max Pooling)和平均池化(Average Pooling)。  
最大池化：最大池化选取局部窗口中的最大值。



### a) 习题

下面哪一项最好地描述了 CNN 中最大池化操作的目的？

- A. reduce the number of feature maps
- B. reduce the size of input image.
- C. reduce the number of model parameters
- D. reduce the number of network layers



ELLE学姐




ECHO学姐




## D. 扁平化层 Flattening Layer

经过卷积层和池化层处理后，特征图依然是多维的。为了将这些特征输入到全连接层（Fully Connected Layer），扁平化层将其转换为一维向量。




## E. 全连接层 Fully Connected Layer

CNN 中的倒数第二层，主要用于将前面提取的特征用于分类或回归任务。



## F. 输出层 Output Layer

输出层负责根据前面的全连接层提取的特征，给出每个类别的概率值。



ELLE学姐



ECHO学姐






## CNN 运算参数

- Channels
- Filter size
- Padding
- Stride
- Dilation
- Activation function


### A. 通道 (Channels)

- ✓ The Conv layer's parameters consist of a set of **learnable filters**.
- ✓ Every filter is small spatially (along width and height) but extends through the full depth of the input volume.
- 卷积层的输出通常会包含多个通道，每个通道代表不同卷积核的特征图。
- 这些特征图共同构成了卷积层的完整输出。



### B. Receptive field 感受野

- 感受野是卷积神经元可以感知的输入区域的空间大小。例如，如果使用  $3 \times 3$  的 filter，每个神经元的感受野就是  $3 \times 3$  的区域。
- Stack of three  $3 \times 3$  conv (stride 1) layers has same effective receptive field as one  $7 \times 7$  conv layer



虽然  $3 \times 3$  的 kernels 偏小，但是会让网络更深、更非线性化、更少的模型参数。



ELLE学姐



ECHO学姐




### C. 步幅 (Stride)

步幅决定了卷积核在图像上移动的步长。

- 步幅为 1 时，卷积核每次移动 1 个像素；
- 步幅为 2 时，卷积核每次移动 2 个像素。


较大的步幅会加速计算，但会减少输出特征图的尺寸。

- 增大步幅可以让卷积核覆盖更大的输入图像区域，更适合提取全局特征（more global features）；
- 而减小步幅可以提取更精细的局部特征（finer and more local details）。



### D. 填充 (Padding)

图像的边缘像素无法被完整卷积处理，因此输出的特征图尺寸比原始输入图像小。



- Padding 是指在输入图像的边缘添加额外的像素。（addition of extra pixels around the edge）
- 之后，卷积核在处理图像时可以覆盖到图像的边界区域，不会丢失图像边缘的信息

填充的主要目的是调整卷积操作后输出的空间尺寸，并保留图像边界的空间信息。（preserve spatial information at the borders）



ELLE学姐



ECHO学姐






## E. 膨胀 (Dilation)

通常, 当在图像上应用一个  $3 \times 3$  的卷积核时, 每个卷积操作的输出只受到输入图像中  $3 \times 3$  像素区域的影响。

**膨胀 (Dilation)** 是为了拥有更大的感受野 (receptive field), 即影响卷积输出的图像区域更大。

### a) 膨胀系数


- 当膨胀系数设为 2 时, 卷积核不再仅仅作用于连续的  $3 \times 3$  像素块。
- 相反, 它会扩展到  $5 \times 5$  的区域, 但是只有间隔一个像素的格点上的像素会被使用, 即在原始  $3 \times 3$  卷积核对应的位置上扩展出去的点。



3 by 3 filter with dilation of 2

## F. Convolution 输出尺寸公式

**N=7, F=3, Stride = 3? 不行!**



Output size:  
 $(N - F) / \text{stride} + 1$

e.g.  $N = 7, F = 3$ :

stride 1  $\Rightarrow (7 - 3) / 1 + 1 = 5$

stride 2  $\Rightarrow (7 - 3) / 2 + 1 = 3$

stride 3  $\Rightarrow (7 - 3) / 3 + 1 = 2.33 \therefore \backslash$

J, K: Image dimensions

M, N: Kernel (Filter) dimensions

P: Padding size

s: stride

The size of the activation map is  $(1 + (J + 2P - M) / s) \times (1 + (K + 2P - N) / s)$



ELLE学姐




ECHO学姐



# ResNet

引入了“残差连接 residual connections”(或称为“跳跃连接 skip connections”),使得某一层的输出不仅仅依赖于前一层的输出,还包括更前面层的输出。

这种结构允许网络在增加层数时更有效地训练,一定程度缓解了网络中的**梯度消失**、**梯度爆炸**、**数据消失**(data vanish)的问题。



## a) 习题

What is the key benefit of CNNs over traditional ANNs (人工神经网络) for image classification?

- A. CNNs are computationally less expensive.
- B. CNNs automatically learn hierarchical features.
- C. CNNs require fewer network layers.
- D. CNNs can learn nonlinear mappings.



ELLE学姐



ECHO学姐



# Training

## A. Loss function

A loss function is used to **compute the model's prediction accuracy from the outputs**

- ◆ *Most commonly used: categorical cross-entropy loss function*

The training objective is to minimise this loss


**The loss guides the backpropagation process** to train the CNN model

**Gradient descent based methods, such as Stochastic gradient descent and the Adam optimizer, are commonly used algorithms for optimization**

## B. Training Methodology

在模型的训练过程中，数据通常被分为**训练集**、**验证集**和**测试集**。

- ◆ **训练集 train**：训练模型；通过反向传播和优化算法来调整模型的参数。
- ◆ **验证集 valid**：监控模型的性能；超参数调优。主要目的是**防止模型过拟合**，在训练过程中监控模型的泛化能力。
- ◆ **测试集 test**：用于评估模型的最终性能，测试集的数据在整个训练过程中不会被使用，以确保模型的评估结果是真实的泛化表现。



ELLE学姐



ECHO学姐




### C. 欠拟合&过拟合

Monitor the loss on training and validation sets during the training iteration.

#### a) Underfitting 欠拟合

- ◆ If the model performs **poorly on both training and validation sets**
- ◆ 模型在训练集和验证集上的表现都较差。
- ◆ 模型没有足够的复杂度来学习数据中的模式，无法准确捕捉输入与输出之间的关系。



#### b) Overfitting 过拟合


- ◆ If the model performs **well on the training set compared to the validation set**
- ◆ 模型在训练集上的表现非常好，但在验证集上的表现明显变差。
- ◆ 模型过于“记住”训练集中的数据细节，导致在处理新数据（验证集）时表现不佳。

### D. Common methods to mitigate overfitting

- More training data
- Early Stopping
- Data Augmentation
- Regularization (weight decay, dropout)
- Batch normalization

#### a) More training data

- Costly
- Time consuming
- Need experts for specialized domains



#### b) Early stopping

- 在训练过程中，模型的训练误差会不断减小，但验证误差可能会在某一时刻开始增大，这表示模型开始**过拟合**训练数据。
- 早停通过在**验证误差最小时**终止训练，从而**避免过拟合**。

#### c) Data Augmentation

- 通过对原始数据集进行变化生成新的数据实例，以此来扩充数据集。
- 通过引入多样的数据变体，帮助模型学习如何处理不同的输入变化，从而提高模型的泛化能力（降低过拟合），提高鲁棒性（robustness）。



ELLE学姐



ECHO学姐



## d) Regularization

**Weight decay**

- ◆ 在训练集的损失函数上增加了一个惩罚项，以降低学习模型的复杂性

**Dropout**

- ◆ 通过在训练过程中随机丢弃（即将输出置为 0）一部分神经元，防止模型对特定的神经元过度依赖，**增强模型的泛化能力**。

## e) Batch Normalization

通过对每个小批量数据进行归一化处理，批量归一化能够减少**内部协变量偏移**（**internal covariate shift**），加速模型训练过程，使模型对超参数的选择更为鲁棒。降低梯度对参数尺度（scale）的依赖。

## f) 习题

Which one of the following statements about data augmentation for image classification using CNNs is correct?

- A. Augmentation increases the number of parameters in the model.
- B. Augmentation reduces the size of the dataset to speed up training.
- C. Augmentation generates new training data by transforming the existing data.
- D. Augmentation reduces the depth of the network for better performance.

E. 迁移学习 (Transfer Learning)

拥有丰富数据的领域被称为**源域**(Source)，目标任务被称为**目标域**(Target)。迁移学习的关键在于利用源域中的知识来增强目标域中的学习效果。

通过使用**在大规模数据集上预训练的模型来初始化或作为新任务的起点**，可以显著提高小（new）数据集上的学习效率和性能。

## a) 习题

What does transfer learning with CNNs involve?

- A. Training a model from scratch for each new task.
- B. Using a pretrained model and fine-tuning it for a new task.
- C. Converting image data to text data to facilitate learning.
- D. Combining multiple CNNs into a single model for better performance.



ELLE学姐



ECHO学姐



# Evaluation Metrics

## A. Recap

Confusion matrix for binary classification

|        |   | Prediction             |                        |
|--------|---|------------------------|------------------------|
|        |   | P                      | N                      |
| Actual | P | # True Positives (TP)  | # False Negatives (FN) |
|        | N | # False Positives (FP) | # True Negatives (TN)  |

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (P)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (R)$$

$$F1 = \frac{2PR}{P + R}$$

## B. Multi-class Metrics

How to calculate metrics in this case?

There are two types of metrics:

1. Calculate metrics for each class, then average each metric over all classes. This is **macro-metrics** calculation. E.g.,

$$TPR = \frac{1}{K} \sum_{i \in K} \frac{TP_i}{TP_i + FN_i}$$

2. Add up values for all classes, creating a new confusion matrix 2 \* 2, then calculate all metrics as usual. This is called **micro-metrics** calculation. E.g., over all classes. This is macro-metrics calculation. E.g.,

$$TP = \sum_{i \in K} TP_i$$

|                  |       | True values |     |       |
|------------------|-------|-------------|-----|-------|
|                  |       | Dog         | Cat | Panda |
| Predicted values | Dog   | TP          | FP  |       |
|                  | Cat   |             |     |       |
|                  | Panda | FN          | TN  |       |



ELLE学姐



ECHO学姐





a) 计算

|                      |        | <i>gold labels</i>                  |                                         |                                          |                                             |
|----------------------|--------|-------------------------------------|-----------------------------------------|------------------------------------------|---------------------------------------------|
|                      |        | urgent                              | normal                                  | spam                                     |                                             |
| <i>system output</i> | urgent | 8                                   | 10                                      | 1                                        | $\text{precision}_u = \frac{8}{8+10+1}$     |
|                      | normal | 5                                   | 60                                      | 50                                       | $\text{precision}_n = \frac{60}{5+60+50}$   |
|                      | spam   | 3                                   | 30                                      | 200                                      | $\text{precision}_s = \frac{200}{3+30+200}$ |
|                      |        | $\text{recall}_u = \frac{8}{8+5+3}$ | $\text{recall}_n = \frac{60}{10+60+30}$ | $\text{recall}_s = \frac{200}{1+50+200}$ |                                             |

| Class 1: Urgent  |                | Class 2: Normal |             | Class 3: Spam |             | Pooled      |            |
|------------------|----------------|-----------------|-------------|---------------|-------------|-------------|------------|
|                  |                |                 |             |               |             |             |            |
|                  | true<br>urgent | true<br>normal  | true<br>not | true<br>spam  | true<br>not | true<br>yes | true<br>no |
| system<br>urgent | 8              | 11              |             | 200           | 33          | 268         | 99         |
| system<br>not    | 8              | 340             |             | 51            | 83          | 99          | 635        |

$\text{precision} = \frac{8}{8+11} = .42$     
 $\text{precision} = \frac{60}{60+55} = .52$     
 $\text{precision} = \frac{200}{200+33} = .86$     
 $\text{microaverage precision} = \frac{268}{268+99} = .73$

$\text{macroaverage precision} = \frac{.42+.52+.86}{3} = .60$



ELLE学姐



ECHO学姐



# 知识蒸馏

## CNN

- ◆ 从低层信息学习到高层信息，越高，信息越全局，也越抽象。
- ◆ 可以识别对象的位置或方向的变换，抗性高。

## CNN 组成部分

- ◆ 卷积层：信息提取。
- ◆ 激活函数：对模型引入非线性， $\text{ReLU}=\max(0,x)$ 。
- ◆ 池化层：下采样、pooling、subsampling，用于减少特征图的尺寸（维度）。
- ◆ 扁平化层：flatten 将多维的特征转成一维向量。
- ◆ 全连接层和输出层：将前面提取的特征用于分类或者回归。

## CNN 运算参数

- ◆ Stride 步幅（步长）：较大的步长会加速计算，但是会减少输出特征图的尺寸。
- ◆ Padding 填充：边缘像素无法被完整的卷积处理，通过填充，避免丢失图像的边缘信息。
- ◆ Dilation 膨胀：会让卷积核获得更大的感受野（receptive field），特征图的尺寸也会变小。
- ◆ 感受野的判断（e.g. 三次使用  $3 \times 3$  等于一次  $7 \times 7$ ；优势方面）
- ◆ 计算模型参数的公式、计算卷积之后纬度的计算。

## CNN Models

- ◆ Resnet: skip connections 跳连。允许网络在增加层数时，更有效训练，缓解梯度消失于爆炸。（后面利用到跳连的网络都有此特点，例如 Unet）
- ◆ SENet: 通过对每个通道的特征进行自适应重新加权（weight each channel adaptively），增强了网络的特征表达能力。
- ◆ DenseNet 密集连接结构使得网络在深度增加的同时，可以维持 较低的计算复杂度和参数数量。
- ◆ EfficientNet: 使用复合缩放（Compound Scaling）方法来同时缩放网络的深度（Depth）、宽度（Width）和分辨率（Resolution）的技术，从而实现高精度和计算效率。



ELLE学姐



ECHO学姐



CPU EDUCATION



新南echo学姐：  
echo68cpu



新南ella学姐：  
lilith0619

**CPU·EDU成长有你陪伴**  
**· 让海外学习更轻松 ·**



盗版必究索赔

盗版必究索赔

盗版必究索赔

盗版必究索赔

盗版必究索赔

盗版必究索赔

盗版必究索赔



ELLE学姐



ECHO学姐