



COMP9517

期末班

Final-4 期末课讲解

TUTOR: Plum

时长: 2 小时

本节内容预览:

1. Selective Search
 2. R-CNN/Fast R-CNN/Faster R-CNN
 3. YOLO、RetinaNet
 4. FCN、Unet、Mask R-CNN
 5. Change detection
 6. Sparse/Dense motion estimation
- 3-8 题



Object Detection

A. Loss function

目标检测结合了目标分类和定位任务，其目标是识别图像中所有关注对象，并预测它们的边界框位置。

- ◆ 分类：使用 softmax loss 预测每个对象类别的概率。
- ◆ 定位：通过 regression loss 预测对象的边界框（框的左上角位置 x,y 以及其宽度 w 和高度 h ）。

B. 多个物体检测

如何检测一张图中的多个对象？

难点：图像中的目标数量和大小可变，且每个目标的位置也不固定。

解决方案：使用区域提议（region proposals）方法来快速生成，可能包含目标边界框的提议。



ELLE学姐



ECHO学姐




R-CNN

- R-CNN (Regions with CNN features) : CNN 与区域提议方法结合。
- 通过提取区域兴趣 (Regions of Interest, RoI) 并利用 CNN 特征进行分类。

A. 四个主要步骤

R-CNN

1. Takes an input image
2. Extracts around 2000 (2k) bottom-up region proposals
3. Compute features for each proposal using a CNN
4. Classifies each region using class-specific linear SVMs.



1. 输入图像;
2. 利用区域提议算法 (如 Selective Search) 提取出约 2000 个候选区域 (RoI), 这些区域包含了可能的对象。
3. 对每个候选区域进行尺寸归一化 (固定尺寸), 输入到 CNNs 中, 提取特征。
4. 使用类别特定的支持向量机 (SVM) 对每个区域 (独立地) 进行分类, 同时通过边界框回归来精确定位对象。

B. 缺点

- 过程比较慢, 每个区域需要独立处理 (Resize 调整成统一大小、CNN 提取特征、SVM 分类、Linear Model 回归), 计算成本高。



ELLE学姐




ECHO学姐



SPP-Net

在传统的 CNN 中，输入图像的大小通常是固定的。（FCL 要求）

然而，实际应用中的图像和对象区域的大小往往不同，因此需要一种方法将特征映射调整为统一大小。



A. “Pool” features into a common size

SPP-Net 引入空间金字塔池化 (Spatial Pyramid Pooling)

- 将整张图像输入 CNNs (resnet)，生成共享的特征图 (Feature Map)。即，允许网络在不需要图像尺寸固定的情况下提取特征（接受任意大小的图像，卷积运算之后，特征图的尺寸可能不同，但是经过 SPP 都一样！）

B. 优缺点

a) 优点

- SPP-Net solved the R-CNN problem of being slow at test time
- SPP-Net improves R-CNN by removing the need to warp region proposals

b) 缺点

- Problems inherited from R-CNN: Still no end-to-end training



ELLE学姐




ECHO学姐



Fast R-CNN

传统的 R-CNN 存在计算开销大、训练和测试速度慢等问题，特别是在处理大量候选区域时需要重复地对每个区域进行卷积操作，效率较低。

Fast R-CNN 提出了通过一次卷积计算整张图像的特征图，然后在特征图上提取候选区域特征（和 SPP 不一样）。



A. 步骤

- **Step1:** 将整张输入图像通过 CNNs（如 VGG16）生成特征图，而不再对每个候选区域单独计算。
- **Step2:** 使用区域提议方法在原图上生成候选区域（RoI）。
- **Step3:** 在特征图上裁剪出每个候选区域（RoI），并通过 RoI Pooling 层将其转换为固定大小的特征表示。（如 7×7 ）
- **Step4:** 将每个候选区域的特征输入到 FC layer + Softmax 预测对象的位置和类别。

B. 优点

- Training is end-to-end, using multi-task loss
- High detection quality (high mAP) than R-CNN

C. 缺点

Fast R-CNN 的主要瓶颈在于 Region proposals 的生成较为耗时。

为了解决这个问题，Faster R-CNN 提出了 Region Proposal Network (RPN)，直接在特征图上生成区域提议。



ELLE学姐



ECHO学姐




D. RoI pooling

在目标检测任务中，Fast R-CNN 需要对候选区域（RoI）进行特征提取。

a) 步骤

首先，将原图上的候选区域映射到特征空间中。



空间比例 s 计算

$$s = \frac{\text{Input Image Size}}{\text{Feature Map Size}}$$

Example: If input size is 224×224 and feature map is 14×14 , then

$$s = \frac{224}{14} = 16$$

坐标转换（向下取整）



Example: If the bounding box in the original image is (100, 50, 200, 150):

$$x'_1 = \frac{100}{16} = 6.25, \quad y'_1 = \frac{50}{16} = 3.125$$

$$x'_2 = \frac{200}{16} = 12.5, \quad y'_2 = \frac{150}{16} = 9.375$$

Problem: Region features slightly misaligned (ROI Align, Mask R-CNN)

How do resize the $512 \times 5 \times 4$ region to e.g., a $512 \times 2 \times 2$ tensor?



Divide into 2×2 grid of (roughly) equal subregions

将 5×4 区域划分 2×2 网格 $\rightarrow$ 每个子区域 $\approx 2.5 \times 2 \rightarrow$ 实际取整为 2×2 （取整）




ELLE学姐



ECHO学姐



每个子区域进行 **max-pool**



RoI Pooling 将特征空间中每个不同大小候选区域划分为固定数量的网格，对每个网格区域执行最大池化操作，得到一个固定尺寸的特征表示。

Faster R-CNN


A. Region Proposal Network

RPN 替换了早期的 Selective Search，直接在特征图上生成 region proposals，解决了 Fast R-CNN 中生成 region proposals（慢）成为性能瓶颈的问题。

B. 非极大值抑制 (NMS)

在整个图像上，多个滑动窗口生成了大量的候选区域。例如，一个 11×15 的窗口区域，每个窗口 9 个 Anchor 框，最终会产生 $11 \times 15 \times 9 = 1485$ 个候选区域。

这些区域高度重叠，因此需要通过后续步骤来减少冗余，保留重要的候选框。



C. Online hard example mining (OHEM)

在目标检测中，正负样本比例不均衡的问题十分突出：背景区域（负样本）数量远多于目标区域（正样本），这会导致模型更倾向于学习背景特征而非目标物体特征。

OHEM 方法通过修改随机梯度下降 (SGD) 的样本选择策略，优先训练那些难以正确分类的样本（即损失较高的样本）。



ELLE学姐



ECHO学姐



Two-stage vs One-stage Detectors

Two-stage: 先获得 RoIs, 然后再分类

- R-CNN、Fast R-CNN、Faster R-CNN、Mask R-CNN

One-stage: 直接一个网络搞定

- SSD、YOLO、RetinaNet

为什么一阶段的方法准确率有所落后?


- Extreme foreground-background class imbalance encountered.

Semantic Segmentation

A. FCN

Fully Convolutional Networks

FCN 在网络结构上去除了全连接层, 完全由卷积层组成, 使得它能够对任意尺寸的输入图片进行分割预测。(End2End)



Components: Convolutional
layers+Downsampling(encoder)+Upsampling(decoder)

a) Unpooling/upsampling

池化用来减少特征图的尺寸 (e.g. Max Pooling), 以降低计算量并增强特征的抽象性。

然而, 图像分割等任务需要恢复特征图的原始尺寸, 以便得到与输入图像同样分辨率的输出。因此, 上采样 (Unpooling) 操作被引入, 它用于逆转池化过程, 将较小的特征图放大至原始尺寸。




ELLE学姐




ECHO学姐



b) Nearest Neighbour




c) Unpooling




d) Max-Unpooling

记录最大值的位置

B. transposed convolution

转置卷积将卷积操作反向进行，通过一个小尺寸的特征图生成一个大尺寸的输出。

另外一个例子




ELLE学姐



ECHO学姐




C. U-net





Mask R-CNN

Faster R-CNN 的扩展，用于实例分割，并且能够达到像素级别的分割。



在 Faster R-CNN 的基础上增加了一个分支进行实例分割，即在每个感兴趣区域（RoI）内预测分割掩码。

a) 习题

What kind of neural network is most suited for image segmentation tasks?

What kind of neural network is most suited for object detection tasks?

- A. Multilayer perceptron (MLP)
- B. Fully convolutional network (FCN)
- C. Region proposal network (RPN)
- D. Recurrent neural network (RNN)



ELLE学姐



ECHO学姐



Motion estimation

A. Change detection

变化检测、用于检测在静止背景中移动的物体



- 物体的前后边缘在每帧中只移动几个像素。
- 通过从当前帧 I_t 中减去前一帧 I_{t-1} （连续帧差分），可以识别出明显变化的边缘像素，这些像素与零值有显著不同。

a) 图像减法


Step1: 背景图像提取

- 从视频序列的起始几帧中提取背景图像。
- 目的：获取一个纯粹的背景图像，以便后续的帧差分操作。




Step2: 帧差分

- 将背景图像从每一后续帧中减去，生成差分图像。
- 目的：可以突出显示前景物体，即那些与背景图像有显著差异的部分。
-





Step3: 差分图像阈值化和增强

- 对差分图像进行阈值化处理，去除噪声并增强邻近区域的融合。
- 目的：识别出前景物体的轮廓。




Step4: 检测结果的可视化

- 将检测到的 bounding box 加在输入帧上，以便直观地查看检测结果。



ELLE学姐



ECHO学姐




Sparse motion estimation

稀疏运动场 (sparse motion field) 可以通过识别在时间 t 和 $t + \Delta t$ 拍摄的两张图像中对应的点对来计算。

假设: 关注点 (interesting points) 及其邻域的强度 (intensity) 在时间上几乎保持不变。


步骤

- ◆ 在时间 t 检测有趣点。
- ◆ 在时间 $t + \Delta t$ 搜索对应点。



A. 对应点搜索 (模版匹配)

在稀疏运动估计中, 需要在当前帧 I_t 中找到有趣点, 并在下一帧 $I_{t+\Delta t}$ 中找到对应的匹配点。



搜索步骤

1. 在图像 I_t 中选取一个有趣点 P_i
2. 以 P_i 为中心, 在图像 I_t 中取一个邻域区域 T
3. 假设移动量有限, 这样可以减少搜索范围。在图像 $I_{t+\Delta t}$ 中的搜索区域内, 寻找与 T 最匹配的邻域 Q_i

a) Similarity Measures

知道哪个指标需要被 max/min

- Max: Cross-correlation、Mutual information
- Min: Sum of absolute differences、Sum of squared differences



ELLE学姐



ECHO学姐



Dense motion estimation

稠密运动估计指在图像的**每一个像素点**上计算运动矢量。基本假设：

- 在一定的时间间隔内，物体的反射率（reflectivity）和光照（illumination）条件不发生变化。
- 在此时间间隔内，物体到摄像机和光源的距离没有显著变化。

A. Optical Flow Equation

光流方程用于估计运动场的经典方法，描述了像素点在**两个连续帧之间的运动关系**。（运动矢量：速度）

光流方程提供了**每个像素位置上的一个约束**，但它并没有唯一解，因此需要引入**额外的约束**来解决。

a) 习题

Which one of the following statements about motion analysis is incorrect?

- A. Detection of moving objects by subtraction of successive images in a video works best if the background is constant.
- B. Sparse motion estimation in a video can be done by template matching and minimising the mutual information measure..
- C. Dense motion estimation using optical flow assumes that each small neighbourhood remains constant over time.
- D. Optical flow provides an equation for each pixel but requires further constraints to solve the equation uniquely.



ELLE学姐



ECHO学姐



Object tracking

A. Bayesian inference


a) Problem Definition

运动物体的状态 State

- 运动物体的状态 (state) 会随着时间的不断变化。
- 状态用随机变量 X_i 表示, 可以包括任何感兴趣的量, 如位置、速度、加速度、形状、亮度、颜色等。
- 具体的状态值用 x_i 表示。

状态的测量 Measurements

- 每个时间点, 都会对状态进行测量 (measure)。
- 测量用随机变量 Y_i 表示 (从图像中提取的特征)。
- 具体的测量值用 y_i 表示。



状态估计: 将多次测量结合起来, 用以估计物体的状态。

b) Independence Assumptions

状态的独立性假设

- ◆ 当前状态只依赖于最近的一个过去状态:


$$P(X_i | X_0, X_1, \dots, X_{i-1}) = P(X_i | X_{i-1})$$

测量的独立性假设

- ◆ 测量只依赖于当前的状态:

$$P(Y_i, Y_j, \dots, Y_k | X_i) = P(Y_i | X_i) P(Y_j, \dots, Y_k | X_i)$$

These assumptions imply the tracking problem has the structure of inference on a hidden Markov model



Hidden Markov Model



ELLE学姐



ECHO学姐



B. Kalman filtering

- 假设动态模型（状态转移模型）和测量模型都是线性的，并且噪声是加性高斯（additive Gaussian）噪声。

C. Particle Filtering

- 状态估计不仅限于线性和高斯情况。
- 应对非线性和非高斯情况。
- 此处的并无假定模型是否可以参数化。

a) 习题

Which one of the following statements about object tracking is incorrect?

- A. The particle filtering method assumes that the dynamics model and the measurement model can be parameterized.
- B. The hidden Markov model assumes that the measurements depend only on the current state of the objects.
- C. The prediction step of Bayesian inference assumes that the current state of the objects depends only on the previous state.
- D. The Kalman filtering method assumes that the dynamics and measurement noise are additive Gaussian.



ELLE学姐



ECHO学姐



CPU EDUCATION



新南echo学姐：
echo68cpu



新南ella学姐：
lilith0619

CPU·EDU成长有你陪伴
· 让海外学习更轻松 ·